

I. FLOPs (S, B)

Общая формула для conv 2D:

для 1^{го} выходного канала 1 фильтру обр. область

$[C_{in}, K, K]$

СЧ-но, кол-во MAC $\rightarrow C_{in} K^2$

Т.к. 1 MAC = 2 FLOPs $\Rightarrow$ 1 вых. канал требует $2 C_{in} K^2$ операций

Эти операции нужно провести для C_{out} каналов.

$2 C_{in} C_{out} K^2$ FLOPs

Фильтры свиз. по размерам $H_{out} W_{out} \Rightarrow 2 C_{in} C_{out} H_{out} W_{out} K^2$

Всего картинок $B \Rightarrow 2 B C_{in} C_{out} H_{out} W_{out} K^2$

Conv 1:

$$FLOPs_1 = 2 \cdot B \cdot 3 \cdot 32 \cdot \frac{5}{2} \cdot \frac{5}{2} \cdot 7^2 = 2352 B S^2$$

Pooling и Relu - memory-based operations $\Rightarrow$ возьмем $FLOPs(Pool \& Relu) = 0$

Conv 2:

$$FLOPs_2 = 2 \cdot B \cdot 32 \cdot 64 \cdot \frac{5}{4} \cdot \frac{5}{4} \cdot 5^2 = 6400 B S^2$$

Conv 3:

$$FLOPs_3 = 2 \cdot B \cdot 64 \cdot 128 \cdot \frac{8}{8} \cdot \frac{5}{8} \cdot 3^2 = 2304 B S^2$$

Conv 4:

$$FLOPs_4 = 2B \cdot 128 \cdot 256 \cdot \frac{5}{8} \cdot \frac{5}{8} \cdot 1^2 = 1024BS^2$$

Conv 5:

$$FLOPs_5 = 2B \cdot 256 \cdot 256 \cdot \frac{5}{16} \cdot \frac{5}{16} \cdot 3^2 = 4608BS^2$$

Conv 6:

$$FLOPs_6 = 2B \cdot 256 \cdot 512 \cdot \frac{5}{16} \cdot \frac{5}{16} \cdot 1^2 = 1024BS^2$$

$$FLOPs_{conv} = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) BS^2 = 17712 BS^2$$

Linear Layers:

$$FLOPs_{Linear} = 2B N_{in} N_{out} + \underbrace{N_{out}}_{m.k. \text{ bias} = true}$$

$$FLOPs_{fc1} = 2B \cdot 512 \cdot 256 + 256B = 262400B$$

$$FLOPs_{fc2} = 2B \cdot 256 \cdot 100 + 100B = 51300B$$

$$FLOPs_{Linear} = 313700B$$

Unno 20: $FLOPs_{total} = (17712S^2 + 313700)B$

II Memory (S, B)

В eval() память занимают:

- веса модели
- входные тензоры
- промежуц. анализ.
- служебная память cuda

FP32 означает: 1 число = 32 бита = 4 байта

1) Память весов:

$N_{params} = C_{in} C_{out} K^2$ (трюк: $C_{in} K^2$ - это количество весов, а C_{out} - количество фильтров, у нас всего C_{out})

$$N_1 = 3 \cdot 32 \cdot 7^2 = 4704$$

$$N_2 = 32 \cdot 64 \cdot 5^2 = 51200$$

$$N_3 = 64 \cdot 128 \cdot 3^2 = 73728$$

$$N_4 = 128 \cdot 256 \cdot 1^2 = 32768$$

$$N_5 = 256 \cdot 256 \cdot 3^2 = 589824$$

$$N_6 = 256 \cdot 512 \cdot 1^2 = 131072$$

Linear

$$N_{fc1} = 512 \cdot 256 + 256 = 131328$$

$$N_{fc2} = 256 \cdot 100 + 100 = 25700$$

$$N_{params} = 883296 + 131328 + 25700 = 1040324$$

$$M_{params} = 4 \cdot N_{params} = 4161296 \text{ байт} \approx 4 \text{ МБ}$$

$$N_{conv} = \sum_i N_i = 883296$$

3) Пиковая

Пиковая память

$$\underbrace{1285^2}_{\text{input}} + \underbrace{3185^2}_{\text{conv}}$$

$$M_{peak} \approx 4 \text{ МБ}$$

2) Память на вводе

Input: $4 \cdot 3BS^2 = 12BS^2$

Conv 1/relu: $4 \cdot B \cdot 32 \cdot \frac{S}{2} \cdot \frac{S}{2} = 32BS^2$

Max Pool: $4 \cdot B \cdot 32 \cdot \frac{S}{4} \cdot \frac{S}{4} = 8BS^2$

Conv 2/relu, т.к. inplace = true не создает новой выходной тензор $\Rightarrow$ extra-memory = 0

$$4 \cdot B \cdot 64 \cdot \frac{S}{4} \cdot \frac{S}{4} = 16BS^2$$

пример

conv3/relu: $4 \cdot B \cdot 128 \cdot \frac{S}{8} \cdot \frac{S}{8} = 8BS^2$

conv4/relu: $4 \cdot B \cdot 256 \cdot \frac{S}{8} \cdot \frac{S}{8} = 16BS^2$

conv5/relu: $4 \cdot B \cdot 256 \cdot \frac{S}{16} \cdot \frac{S}{16} = 4BS^2$

conv6/relu: $4 \cdot B \cdot 512 \cdot \frac{S}{16} \cdot \frac{S}{16} = 8BS^2$

3296

Global Avg Pool: $B \times 512 \times 1 \times 1 = 512B$

Flatten - новое выдел. мем

Linear 1/Relu: $1024B$

Linear 2: $400B$

3) Пиковая память:

Пиковая память достиг. во время Max Pool:

$$\underbrace{12BS^2}_{\text{input}} + \underbrace{32BS^2}_{\text{conv1}} + \underbrace{8BS^2}_{\text{выход max-pool}} = 52BS^2$$

4 MiB

$$M_{\text{peak}} \approx 4 \text{ MiB} + 52BS^2 \text{ байт}$$

III Latency (S, B, Q)

Обозначим через $Q(S, B)$ общую кол-во прочитанных и записанных данных.

$$Q_{conv} = A_{input} + W_{conv} + A_{output}$$

$$Q_{conv} = 44BS^2 + 18816$$

Relu читаем и записыв. рез. одж.

$$Q_{Relu} = A_{read} + A_{write} = 2A$$

$$Q_{Relu} = 2 \cdot 32BS^2 = 64BS^2$$

Итого: $Q(S, B) = 364BS^2 + 8532B + 4161296$

1) Занули CUDA операции имеют фикс. сложность $\sim$ кон.

$$Y \text{ нас } \underbrace{6}_{conv} + \underbrace{7}_{relu} + \underbrace{1}_{maxPool} + \underbrace{1}_{GlobalAvgPool} + \underbrace{2}_{Linear} = 17 \text{ Опер.}$$

$$2) T_{compute} = \frac{F(FLOPs)}{\prod \left(\frac{FLOPs}{s} \right)}$$

↑
процесс.

$$3) T_{memory} = \frac{Q}{BW (\text{пропускн. способность})}$$

Вычисл. и работа с памятью частично прерыв.

Основное время опер. более медл. чем вычисл.

$$\bar{T}_i = \tilde{c} + \max\left(\frac{F_i}{\pi}, \frac{Q_i}{Bw}\right)$$

Полное время запуска цепи

$$T = \sum_{i=1}^n \left[\tilde{c} + \max\left(\frac{F_i(s, B)}{\pi}, \frac{Q_i(s, B)}{Bw}\right) \right]$$

$$Q = (\tilde{c}, \pi, Bw)$$

4) Arithmetic intensity

$$I(s, B) = \frac{17712 Bs^2 + 313344B}{364Bs^2 + 8532B + 4161296} = \frac{FLOPs}{Q}$$